

**UFS**  
 UNIVERSIDADE FEDERAL DE SERGIPE

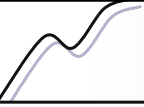

**Roteiro**

- Preparação de Dados
  - ◆ Instâncias e Atributos
  - ◆ Conversão de Atributos
- Redes Neurais Artificiais
  - ◆ Introdução
  - ◆ Modelo de Neurônio MCP
  - ◆ Rede Perceptron
- Exercício

**Inteligência Artificial**



UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa

## *Preparação dos Dados*




### *Instância e Atributos*

- **Instâncias**
  - ◆ padrões, exemplos, objetos, registros, pontos, amostras, casos, entidades
- **Atributos**
  - ◆ cada instância é formada por um conjunto de atributos
  - ◆ variável, campo, característica



UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Instância e Atributos


Inteligência Artificial

Nome	Febre	Enjôo	Mancha	Diagnóstico
João	sim	sim	pequena	doente
Pedro	não	não	pequena	saudável
Maria	sim	sim	grande	saudável
José	sim	não	pequena	doente
Ana	sim	não	grande	saudável
Leila	não	não	grande	doente

valor de um atributo



UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa




## Instância e Atributos


Inteligência Artificial

■ Descarte de atributos

Nome	Febre	Enjôo	Mancha	Dor	Salário	Diagnóstico
João	sim	sim	pequena	sim	1000	doente
Pedro	não	não	pequena	não	1100	saudável
Maria	sim	sim	grande	não	600	saudável
José	sim	não	pequena	sim	2000	doente
Ana	sim	não	grande	sim	1800	saudável
Leila	não	não	grande	sim	900	doente




UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa




## Valores de Atributos

UFS  
50  
Inteligência Artificial

- Para atribuir valores a atributos, é necessário uma **escala de medição**
- Regra ou função que associa um **valor numérico** ou **simbólico** a um **atributo**
  - ◆ Mapeia grandeza física em valor do atributo
  - ◆ Exemplo:
    - Associa-se **peso** a um **valor numérico**
    - Associa-se **sexo** aos símbolos **Masculino** e **Feminino**




UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Tipos de Atributos


UFS  
50  
Inteligência Artificial


- **Nominal**
  - ◆ cor, identificação, profissão, ...
- **Ordinal**
  - ◆ gosto (ruim, médio, bom), dias da semana , ...
- **Intervalar**
  - ◆ temperatura em Celsius, ...
- **Racional**
  - ◆ peso, tamanho, idade, temperatura em Kelvin, ...



UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa

<div> <div>Catagórico (Qualitativo)</div> <div>Numérico (Quantitativo)</div> </div>	Tipo de Atributo	Descrição	Exemplos
	Nominal	Valores são simplesmente nomes (símbolos) diferentes, i.e., atributos nominais provêm apenas informação suficiente para distinguir uma instância de outra: ( $=$ , $\neq$ )	Sexo, Estado Civil, CEP, ...
	Ordinal	Os valores de atributos ordinais provêm informação suficiente para distinguir e ordenar instâncias, i.e.: ( $=$ , $\neq$ ) e ( $<$ , $>$ )	Grau de Educação, Números de Endereço, ...
	Intervalo	Atributos para os quais a diferença entre valores faz sentido, i.e., existe uma unidade de medida com referência (zero) arbitrário. Suporta as operações anteriores e ainda (+, -)	Datas, Temperatura em Fahrenheit, ...
	Razão	Atributos para os quais não apenas a diferença entre valores faz sentido, mas também a razão entre valores (zero é absoluto). Suporta as ops. anteriores e ainda (*, /)	Contagens, Massa, Largura, Corrente Elétrica, Quantidades Monetárias, ...






## Exemplo

■ Identificar **tipo de cada atributo** no cadastro de pacientes abaixo:

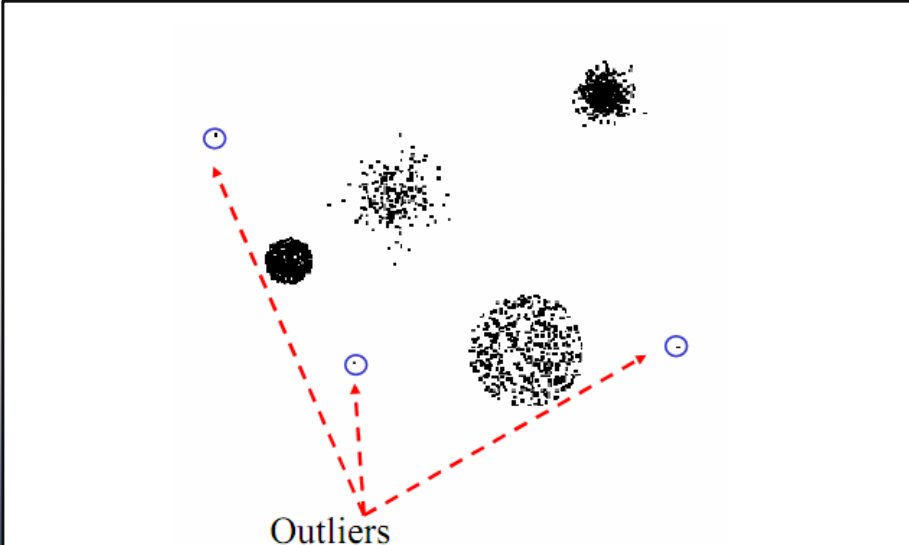
Nome	Temp.	Enjôo	Mancha	Dor	Salário	Diagnóstico
João	37,7	sim	pequena	sim	1000	doente
Pedro	37	não	pequena	não	1100	saudável
Maria	38,2	sim	grande	não	600	saudável
José	39	não	pequena	sim	2000	doente
Ana	37,3	não	grande	sim	1800	saudável
Leila	36,9	não	grande	sim	900	doente

11
63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa




## Outliers



Outliers

12
63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa




## Outliers

13  
63

- Existem várias definições
  
- Basicamente, são instâncias “**anômalas**”
  - ◆ Instâncias que possuem características (valor de um ou mais atributos) diferentes da maioria dos demais
  - ◆ Definição de “**diferente**” usualmente é estatística
  
- Podem ser instâncias **legítimas** ou **não**
  - ◆ Se **não** forem **legítimos**, são o resultado de algum tipo de **ruído**

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Outlier: Friend or Foe?

14  
63

- Mesmo quando *outliers* são legítimos, podem ou não serem desejados...
  - ◆ Por exemplo, em detecção de anomalias essas instâncias são **exatamente aquilo que se procura**
  
  - ◆ Em outras aplicações, **podem não ser o objetivo central**, mas podem ser de interesse se detectados
    - p. ex. genes diferenciados em bioinformática
  
  - ◆ Já em outros casos, **são indesejados**, como em segmentação de mercado
    - interesse por categorias representativas de consumidores

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa


## Conversão de **Valores Categóricos**

- Algumas técnicas trabalham apenas com **variáveis numéricas**
  - ◆ Por exemplo, **Redes Neurais Artificiais**
  - ◆ Variáveis categóricas precisam ser convertidas
- Conversão depende da existência ou não de **ordem** entre os valores
  - ◆ Variáveis **nominais** ou **ordinais**

## Conversão de **Valores Ordinais**

- Para variáveis **ordinais**, a **ordem** dos valores deve ser de alguma maneira mantida
  - ◆ Normalmente associa-se valores inteiros crescentes a cada valor simbólico
    - Por exemplo, {**frio, morno, quente**} = {**1, 2, 3**}





UFS  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

## Conversão de Valores Nominais


Inteligência Artificial

17

63

- **Atributos nominais**
  - ◆ Conversão é feita por **binarização**
  - ◆ Possíveis codificações
    - Codificação inteira – binária
    - Codificação m-de-p
    - **Codificação 1-de-n**

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



UFS  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

## Conversão de Valores Nominais


Inteligência Artificial

18

63

- **Codificação 1-de-n**
  - ◆ Um atributo binário associado a cada valor nominal
  - ◆ Exemplo:
    - Codificar {amarelo, vermelho, verde, azul, laranja, branco}
      - 100000 – amarelo
      - 010000 – vermelho
      - 001000 – verde
      - 000100 – azul
      - 000010 – laranja
      - 000001 – branco

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



UFS  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

## Conversão de Valores Nominais

■ **Codificação 1-de-n**


- ◆ Pode gerar um **número grande** de atributos binários
- ◆ Porém, possui várias propriedades interessantes, dentre elas, manter **eqüidistantes** quaisquer dois vetores binários

Inteligência Artificial

19

63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



UFS  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

## Exercício

■ Converter os dados abaixo para valores numéricos no intervalo [0, 1]

Febre	Enjôo	Mancha	Dor	Diagnóstico
baixa	sim	pequena	A	doente
média	não	média	C	saudável
alta	sim	grande	B	saudável
alta	não	pequena	A	doente
baixa	não	grande	D	saudável
média	não	sem	C	doente

Inteligência Artificial

20

63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa

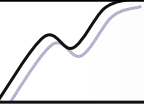

<div> <div> <div>UFS</div> <div> <div>40</div> <div>anos</div> <div>1964-2004</div> </div> </div> <div> <div>UNIVERSIDADE FEDERAL DE SÃO CARLOS</div> </div> </div> <div>Exercício - Resolução</div>							
Febre	Enjôo	Mancha	Dor				Diagnóstico

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa

<div> <div> <div>UFS</div> <div> <div>40</div> <div>anos</div> <div>1964-2004</div> </div> </div> <div> <div>UNIVERSIDADE FEDERAL DE SÃO CARLOS</div> </div> </div> <div>Exercício - Resolução</div>							
Febre	Enjôo	Mancha	Dor				Diagnóstico
0	1	0,33	1	0	0	0	1
0,5	0	0,66	0	0	1	0	0
1	1	1	0	1	0	0	0
1	0	0,33	1	0	0	0	1
0	0	1	0	0	0	1	0
0,5	0	0	0	0	1	0	1

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa

## Redes Neurais Artificiais



### Sistema Nervoso


- Conjunto complexo de **células**
- Determina funcionamento e comportamento dos **seres vivos**
- Unidade fundamental: **neurônio**
  - ◆ Distingue-se das outras células por apresentar excitabilidade
- Engloba o **cérebro**

Inteligência Artificial

24

63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Cérebro


UFS  
40  
anos  
1948-2018  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

- Funciona de forma **inteiramente diferente** dos computadores convencionais
- ◆ 1980
  - Neurônios eram de 100 mil a 1 milhão de vezes **mais lentos** que portas lógicas de silício
- ◆ Hoje
  - Muito **mais lentos** ainda...

Inteligência Artificial

25  
63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Cérebro

UFS  
40  
anos  
1948-2018  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

- **Lentidão compensada** por grande número de neurônios maciçamente **conectados**
- ◆ Para vários tipos de **tarefas complexas**, é muito mais **precisas** (e possivelmente mais **rápido**) que computadores convencionais
  - Visão, audição, reconhecimento, controle, ...

Inteligência Artificial

26  
63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Cérebro


UFS  
40  
anos  
1964-2004  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

- Ocupa uma área de **~1400 cm<sup>3</sup>** e consome apenas **~20W** de energia
- Tem capacidade de construir suas **próprias regras** através da experiência
  - ◆ Cérebro humano
    - **Um milhão de sinapses** por segundo são desenvolvidas nos dois primeiros anos de vida
- Composto por **várias regiões** especializadas
  - ◆ Cada uma com funções específicas

Inteligência Artificial

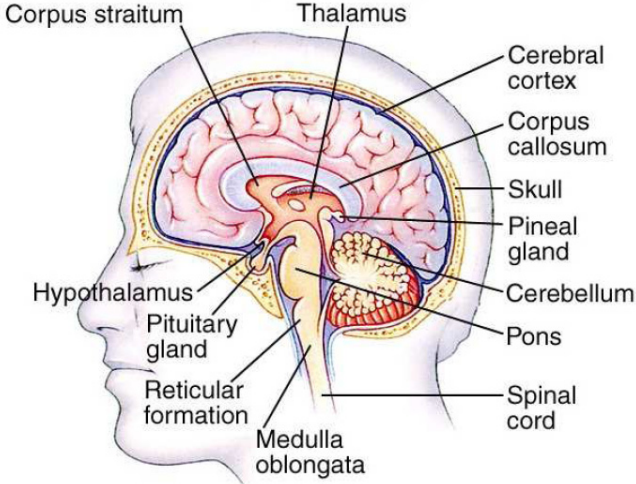


UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa




## Cérebro Humano

UFS  
40  
anos  
1964-2004  
UNIVERSIDADE FEDERAL DE SÃO CARLOS




- **≈ 10 bilhões de neurônios**, cada um dos quais conectado em média a outros 10<sup>4</sup>

Inteligência Artificial



UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



UFS  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

## Por que Redes Neurais?

Inteligência Artificial

- Computadores são eficientes em várias áreas
  - ◆ Entretanto, computação convencional não tem obtido desempenho próximo da natureza em vários domínios
  - **Sistema visual humano**
    - Reconhecer rosto familiar em ambiente estranho (100-200m)
  - **Sonar de morcegos**
    - Reconhece alvos (distância e velocidade)
    - Cérebro do tamanho de uma ameixa

29

63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



UFS  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

## Por que Redes Neurais?


Inteligência Artificial

- Trabalhos em **RNAs** começaram com o desejo de **entender o cérebro**
- Objetivo principal (ainda) hoje é reproduzir seu funcionamento em diversas tarefas
  - ◆ **Paradigma Bio-Inspirado de AM !**
  - ◆ Em particular: **Paradigma Conexionista**

30

63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa




50  
anos  
1964-2014  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

## O que são Redes Neurais?

- **RNAs** são modelos de computação com propriedades particulares:
  - ◆ **Aprender**
  - ◆ **Adaptar**
  - ◆ **Generalizar**
  - ◆ **Eventualmente Organizar**

31

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



50  
anos  
1964-2014  
UNIVERSIDADE FEDERAL DE SÃO CARLOS



## O que são Redes Neurais?


- **Sistemas distribuídos** inspirados no cérebro humano
  - ◆ Compostas por várias unidades de processamento (“**neurônios**”)
  - ◆ Interligadas por um grande número de conexões (“**sinapses**”)
- Eficientes em várias aplicações

32

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa









Inteligência Artificial

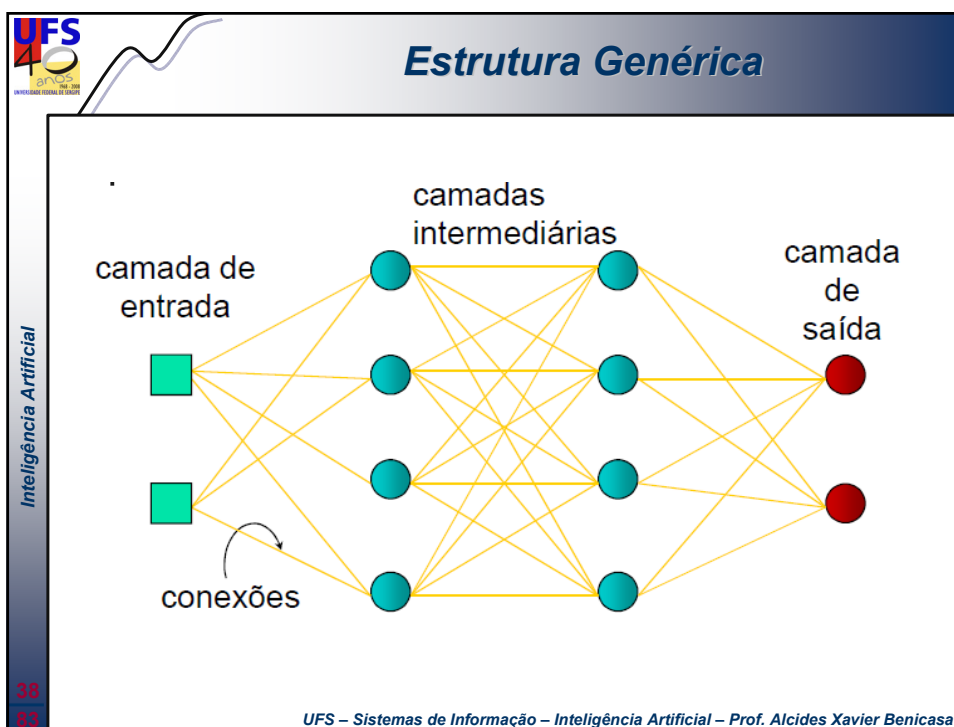
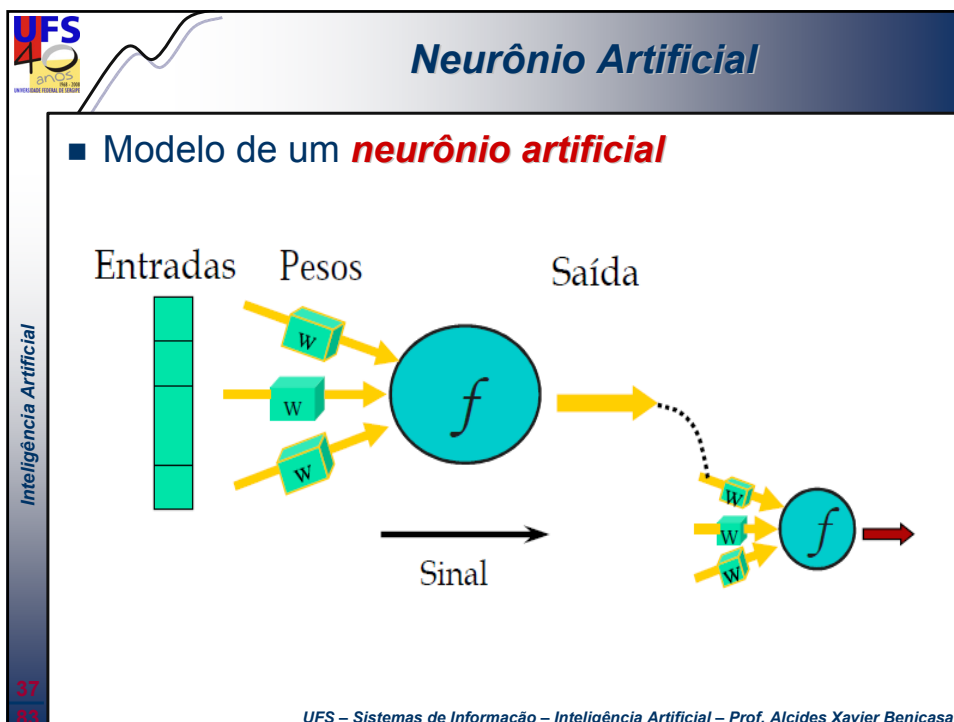
## Neurônio Natural

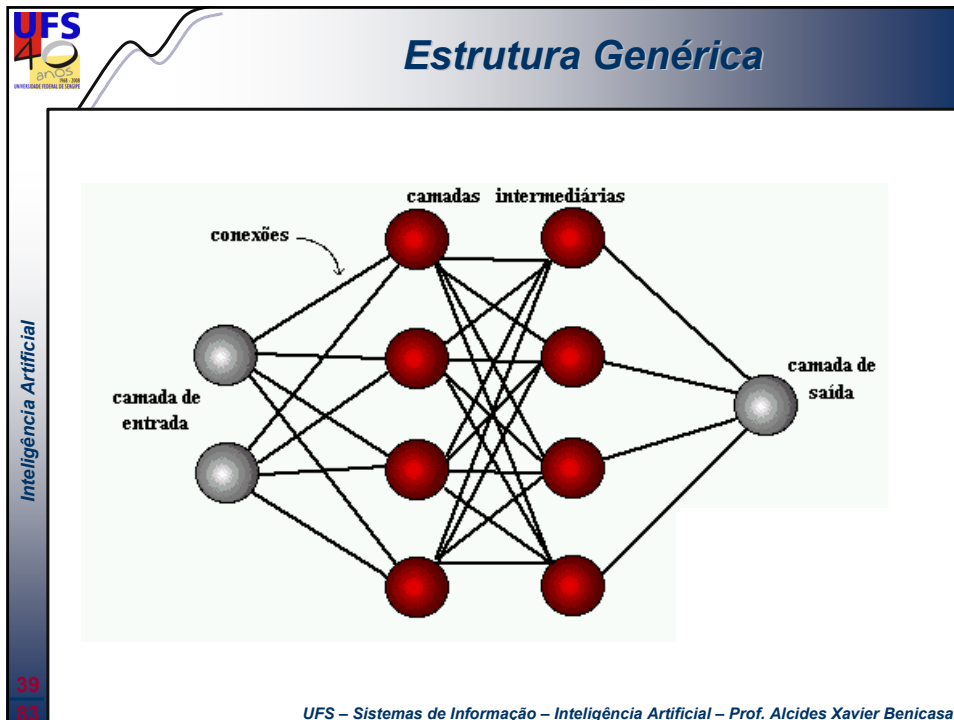
- **Dendritos**
  - ◆ recebem impulsos nervosos (informação) oriundos de outros neurônios e conduzem esses impulsos ao corpo da célula;
- **Corpo da Célula**
  - ◆ informação é processada e novos impulsos são gerados;
- **Axônio**
  - ◆ transmitem os impulsos gerados no corpo da célula a outros neurônios;
- **Sinapse**
  - ◆ ponto de contato entre as terminações dos axônios e os dendritos. Controla a transmissão de impulsos, proporcionando a capacidade de adaptação do neurônio.

36

83

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa





- UFS**  
40  
anos  
1969-2009  
UNIVERSIDADE FEDERAL DE SÃO CARLOS
- ## Conceitos Básicos
- Principais aspectos das RNAs
    - ◆ **Arquitetura**
      - Unidades de Processamento
      - Topologia
    - ◆ **Aprendizado**
      - Paradigmas
      - Algoritmos
- Inteligência Artificial
- 40  
63
- UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



Unidades de Processamento

Inteligência Artificial


41

63

■ Diferentes tipos de neurônios:

- ◆ **Estáticos** ou Dinâmicos
- ◆ **Atemporais** ou Temporais
- ◆ **Lineares** ou Não Lineares

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



Topologia

Inteligência Artificial


42

63

■ Diferentes quantidades de camadas

- ◆ **Uma camada** (Ex. **Perceptron**, Adaline)
- ◆ Multi-camadas (Ex. MLPs, *Radial Basis Function* - RBFs)

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



Inteligência Artificial

## Topologia


■ Diferentes arranjos das conexões

- ◆ Redes **feedforward**
  - Não existem loops de conexões
- ◆ Redes recorrentes
  - Conexões apresentam **loops**
  - Sistema dinâmico...

43

63

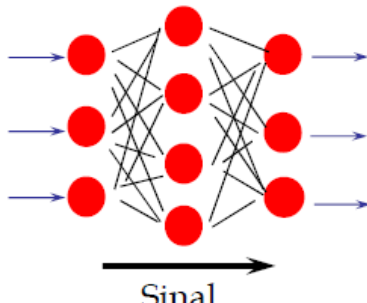
UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



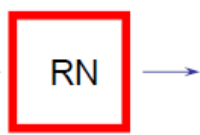
Inteligência Artificial

## Redes Feedforward

■ Sinais seguem em uma única direção



OU




tipo mais comum

44

63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa

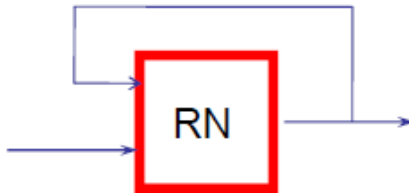


45  
63

Inteligência Artificial

## Redes Recorrentes

- Possuem conexões ligando neurônios de uma camada a neurônios de camada(s) anterior(es)



UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



46  
63

Inteligência Artificial

## Aprendizado

- Paradigmas de **aprendizado**
  - ◆ Indicam como a RNA se relaciona com o ambiente externo
  - ◆ Principais Paradigmas
    - **Supervisionado**
    - Não supervisionado
    - Reforço

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



47  
63

## Aplicações de RNAs


Inteligência Artificial

■ Principais Aplicações  
(Reconhecimento de Padrões)

- **Escrita** (assinaturas, texto manuscrito, ...)
- **Sons** (voz humana - interfaces para deficientes visuais, ...)
- **Imagens** (“fingerprint”, placas de veículos, controle de qualidade, ...)
- **Percepções** (sabor – provador de vinho, cerveja, ...)

47  
63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



48  
63

## Características de RNAs

Inteligência Artificial

■ Principais Características:

- **Valores numéricos** (categóricos demandam conversão);
- Tempo de treinamento pode ser extremamente **longo**;
- Tempo para avaliar um exemplo é relativamente **curto**;
- **Interpretabilidade** usualmente não é possível.

48  
63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Alguns Marcos Históricos


- **McCulloch & Pitts (1943)** – modelo matemático do neurônio;
- **Hebb (1949)** – formulação explícita de uma regra fisiológica para modificação sináptica (“Postulado de **Aprendizado** de Hebb);
- **Rosenblatt (1958)** – rede Perceptron;
- **Minsky & Papert (1969)** – demonstraram **limitações** dos Perceptrons de uma única camada. Sugeriram que não haveria motivo pra acreditar que Perceptrons de múltiplas camadas poderiam superar as limitações...
  - ◆ Diminuíram significativamente os trabalhos sobre RNAs;
- **Hopfield (1982)** – “física com redes neurais”;
- **Kohonen (1982)** – mapas auto-organizáveis;
- **Rumelhart, Hinton & Williams (1986)** – Backpropagation
  - ◆ Retomada definitiva do grande interesse em Redes neurais;
  - ◆ Perceptrons de múltiplas camadas podem aprender problemas não linearmente separáveis

### Modelo de Neurônio **MCP** e Rede **Perceptron**

Se os padrões (vetores) usados para treinar o **Perceptron** são retirados de duas classes linearmente separáveis, então o algoritmo **Perceptron** converge e posiciona a superfície de decisão na forma de um hiperplano entre as duas classes.


## Warren McCulloch,


(Orange, Nova Jérsei, 16 de Novembro de 1898 —  
Cambridge,  
Massachusetts, 24 de  
Setembro de 1969), foi  
um neuroanatomista,  
psiquiatra e  
cibernético  
americano.



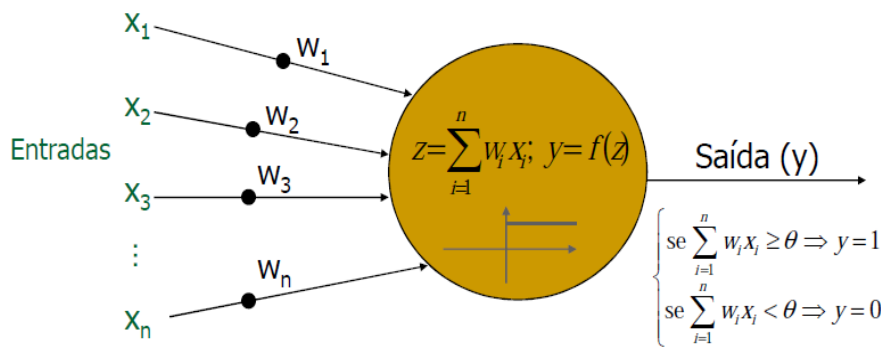
**Walter Pitts**

(23 April 1923 – 14 May 1969), was a logician who worked in the field of computational neuroscience.





## Modelo de Neurônio (McCulloch & Pitts)




- Neurônio de McCulloch & Pitts foi proposto com pesos fixos
- No contexto de AM, tem-se (espaço de hipóteses):

$$H = \{ \mathbf{w} \mid \mathbf{w} \in \Re^n \}; \quad h = ?$$

Inteligência Artificial

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Perceptron

- Rede desenvolvida por **Rosenblatt** em 1958
- Utiliza modelo de neurônio de **McCulloch-Pitts** como unidade de processamento
  - ◆ Com saída em **{-1, +1}**
- Rede mais simples para **classificação** de padrões **linearmente separáveis**
  - ◆ Para classificação binária, resume-se a um neurônio
    - Porém, com **pesos ajustáveis**


Inteligência Artificial



UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa

## Padrões Linearmente Separáveis

- Problemas cuja solução pode ser obtida pela separação de **duas regiões** por meio de **uma reta** (ou **um hiperplano** para o caso n-dimensional).
- ◆ A questão da separação linear pode ser facilmente visualizada para o caso **bidimensional**.

## Conjunto de Pontos Linearmente Separáveis






## Aprendizado

- **Fornecem a base** para o entendimento dos métodos de treinamento para redes formadas por várias unidades;
- **Pesos são inicializados aleatoriamente** e então ajustados sempre que a rede classifica equivocadamente um exemplo de treinamento;
- O **processo é repetido** até que um determinado critério de parada seja alcançado.

## Portas de Limiar Linear

- **Função executada**: comparação da soma ponderada das entradas com um valor de limiar (**threshold**)
- Caso a soma exceda o **limiar**, a saída é **ativada**, permanecendo **desativada** em caso contrário.



$$y = \begin{cases} 1 & \sum w_i x_i \geq \theta \\ 0 & \sum w_i x_i < \theta \end{cases}$$

## Portas de Limiar Linear

- Restritas à solução de problemas que sejam **linearmente separáveis**.

- Exemplo:

- ◆ Considere um neurônio de duas entradas  $x_1$  e  $x_2$ , pesos  $w_1$  e  $w_2$ , limiar  $\theta$  e saída  $y$  executando uma função qualquer.
- ◆ A condição de disparo do neurônio ( $y=1$ ) é então definida por  $x_1 w_1 + x_2 w_2 = \theta$


$$x_2 = -\left(\frac{w_1}{w_2}\right) x_1 + \left(\frac{\theta}{w_2}\right)$$


## Portas de Limiar Linear

- A superfície de decisão de uma porta de limiar linear está **restrita a uma reta**, ou um **hiperplano** para o caso  $n$ -dimensional.

- ◆ Solução para o problema do **E** lógico através de uma porta de limiar linear.

- $w_1 = w_2 = 1$
- $\theta = 1,5$






UFS  
40  
anos  
1974-2014  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

## Exercício

■ Utilizando a mesma porta de limiar linear, resolver as funções **E**, **OU**, **NÃO-E** e **NÃO-OU**.

Inteligência Artificial

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



UFS  
40  
anos  
1974-2014  
UNIVERSIDADE FEDERAL DE SÃO CARLOS

## Perceptron

■ Treinamento:

- ◆ **Supervisionado** (padrões desejados de saída “d”)
- ◆ Dado um padrão de entrada  $\mathbf{x} = [x_1 \dots x_n]$ , tem-se a **correção de erro** para cada peso  $w_i$  ( $i=1, \dots, n$ ) como:
  - $w_i = w_i + \Delta w_i$
  - $\Delta w_i = \eta x_i (d - y) \quad (d \neq y)$
  - $\Delta w_i = 0 \quad (d = y)$

Inteligência Artificial

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa




## ■ Resposta / saída da rede

- ◆ Aplica **função limiar** sobre soma total de entrada recebida por um neurônio

$$Z = \sum_{i=1}^n X_i W_i = \mathbf{x}^T \mathbf{w}$$

$$y = \begin{cases} +1 & \text{se } z \geq \theta \\ -1 & \text{se } z < \theta \end{cases}$$




## ■ Resposta / saída da rede

- ◆ Definindo  $\mathbf{x} = [1 \ x_1 \ \dots \ x_n]^T$  (ou seja,  $x_0 = 1$ ),  
 $\mathbf{w} = [-\theta \ w_1 \ \dots \ w_n]^T$  ( $w_0 = -\theta$ ) e  $v = z - \theta$ :

$$v = \sum_{i=0}^n X_i W_i = \bar{\mathbf{x}}^T \bar{\mathbf{w}}$$

$$y = \begin{cases} +1 & \text{se } v \geq 0 \\ -1 & \text{se } v < 0 \end{cases}$$



## Algoritmo de Treinamento

1 Iniciar todos os pesos  $w_i$

2 Repita

Para cada par de treinamento  $(x, d)$


Calcular a saída  $y$



Se  $(d \neq y)$  Então



Atualizar pesos dos neurônios

Até o erro ser aceitável

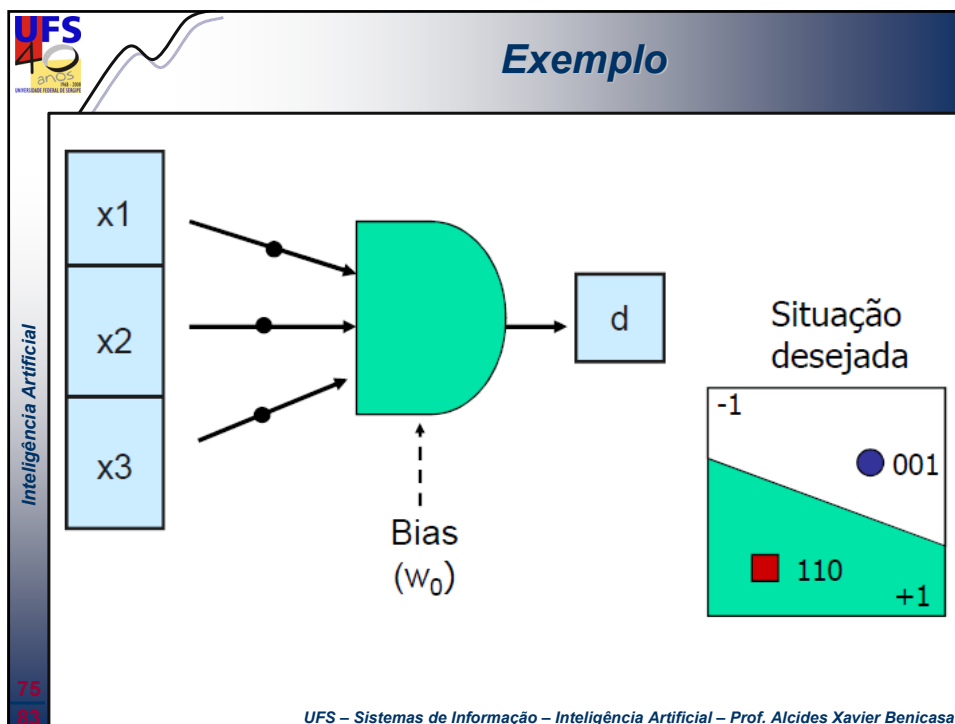
## Algoritmo de Treinamento











**Exemplo**

a) Treinar a rede

a.1) Para o padrão 001 ( $d = -1$ )

Passo 1: definir a saída da rede

$$v = 1(-0.5) + 0(0.4) + 0(-0.6) + 1(0.6) = 0.1$$

$$y = \text{sin}(v) = +1 \text{ (uma vez } 0.1 \geq 0)$$

Passo 2: atualizar pesos ( $d \neq y$ )

$$w_0 = -0.5 + 0.4(1)(-1 - (+1)) = -1.3$$

$$w_1 = 0.4 + 0.4(0)(-1 - (+1)) = 0.4$$


$$w_2 = -0.6 + 0.4(0)(-1 - (+1)) = -0.6$$

$$w_3 = 0.6 + 0.4(1)(-1 - (+1)) = -0.2$$

Inteligência Artificial

76 63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Exemplo

Inteligência Artificial

a) Treinar a rede

a.2) Para o padrão 110 ( $d = +1$ )

Passo 1: definir a saída da rede

$$v = 1(-1.3) + 1(0.4) + 1(-0.6) + 0(-0.2) = -1.5$$

$$y = \text{sin}(\text{al}(v)) = -1 \text{ (uma vez } -1.5 < 0)$$

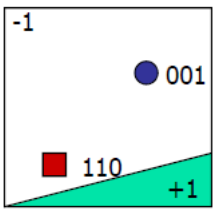
Passo 2: atualizar pesos ( $d \neq y$ )

$$w_0 = -1.3 + 0.4(1)(1 - (-1)) = -0.5$$

$$w_1 = 0.4 + 0.4(1)(1 - (-1)) = 1.2$$


$$w_2 = -0.6 + 0.4(1)(1 - (-1)) = 0.2$$

$$w_3 = -0.2 + 0.4(0)(1 - (-1)) = -0.2$$



77  
63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Exemplo

Inteligência Artificial

a) Treinar a rede

a.3) Para o padrão 001 ( $d = -1$ )

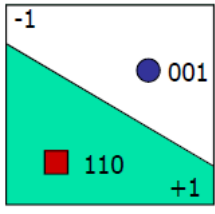
Passo 1: definir a saída da rede

$$v = 1(-0.5) + 0(1.2) + 0(0.2) + 1(-0.2) = -0.7$$

$$y = \text{sin}(\text{al}(v)) = -1 \text{ (uma vez } -0.7 < 0)$$


Passo 2: atualizar pesos ( $d = y$ )

Como  $d = y$ , pesos não precisam atualização



78  
63

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Exemplo

UFS  
 10  
 anos  
 1973-2013  
 UNIVERSIDADE FEDERAL DE SÃO CARLOS

a) Treinar a rede

a.4) Para o padrão 110 ( $d = +1$ )

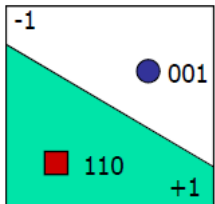
Passo 1: definir a saída da rede

$$v = 1(-0.5) + 1(1.2) + 1(0.2) + 0(-0.2) = 0.9$$

$$y = \text{sinal}(v) = +1 \text{ (uma vez } 0.9 > 0)$$


Passo 2: atualizar pesos ( $d = y$ )

Como  $d = y$ , pesos não precisam atualização



79  
 83  
 Inteligência Artificial

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa



## Exemplo

UFS  
 10  
 anos  
 1973-2013  
 UNIVERSIDADE FEDERAL DE SÃO CARLOS

b) Testar a rede

b.1) Para o padrão 111

$$v = 1(-0.5) + 1(1.2) + 1(0.2) + 1(-0.2) = 0.7$$

$$y = 1 \Rightarrow \text{classe } +1$$

b.2) Para o padrão 000


$$v = 1(-0.5) + 0(1.2) + 0(0.2) + 0(-0.2) = -0.5$$

$$y = -1 \Rightarrow \text{classe } -1$$

80  
 83  
 Inteligência Artificial

UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa





## Exemplo

**b) Testar a rede**

**b.3) Para o padrão 100**


$$v = 1(-0.5) + 1(1.2) + 0(0.2) + 0(-0.2) = 0.7$$

$$y = 1 \Rightarrow \text{classe } +1$$
  

**b.4) Para o padrão 011**

$$v = 1(-0.5) + 0(1.2) + 1(0.2) + 1(-0.2) = -0.5$$


$$y = -1 \Rightarrow \text{classe } -1$$



## Resumo do Treinamento Perceptron

- Saída:  $y = \text{senal}\left(\sum_{i=0}^n w_i x_i\right)$
- Os pesos são corrigidos de acordo com (Regra de Correção de Erro):
 
$$w_i \leftarrow w_i + \Delta w_i$$

$$\Delta w_i = \eta (d - y) x_i$$
- $d$  = valor alvo (-1, +1);  $y$  = valor obtido;  $\eta$  = taxa de aprendizado.
- Interpretação intuitiva:
  - Se exemplo é classificado corretamente  $\Rightarrow (d-y)=0$ ;
  - Se  $d = 1; y = -1 \Rightarrow \bar{\mathbf{W}}^T \bar{\mathbf{X}}$  precisa aumentar
  - Análise análoga pode ser feita para o caso em que o valor alvo é menor do que o valor obtido.



UFS – Sistemas de Informação – Inteligência Artificial – Prof. Alcides Xavier Benicasa

- Campelo, R.J.G.B & Carvallho, A.C.O.F. & Hruschka, E.R. **Notas de Aula**. USP, 2009.
- T.M. Mitchell, **Machine Learning**, McGraw Hill, 1997.
- Braga, A. P., Carvalho, A. C. P. L. F., Ludemir, T. B., **Redes Neurais Artificiais: Teoria e Aplicações**, LTC, 2ª Edição, 2007.
- HAYKIN, Simon. **Neural Networks: A Comprehensive Foundation**. Prentice Hall, 2008.
- RUSSELL, S. & NORVIG, P. **Inteligência Artificial**. Rio de Janeiro, Campus, 2003. 1040p.